1. أنسب بوردة Raspberry Pi (لطالما الموديل سيتحمل عليها)

بما أن الموديل سيعمل محلياً (On-Device) على معالج البوردة وراماتها:

- **الخيار الأول (الأفضل بفارق كبير): Raspberry Pi 5 (نسخة 4GB أو 8GB RAM)**
  - **لماذا؟** معالج Pi 5 أسرع بـ **2.5 إلى 3 مرات** في تشغيل النماذج اللغوية (llama.cpp / Ollama) من Pi 4 بفضل سرعة الرامات الأعلى (LPDDR4X) وتعليمات المعالج الأحدث. الموديل الذي يرد في 6 ثوانٍ على Pi 4 سيرد في **ثانيتين فقط** على Pi 5.
- **الخيار الثاني (إذا كنت ملتزماً بـ Raspberry Pi 4 Model B :(Pi 4 (نسخة 4GB أو 8GB RAM)**
  - **شرط أساسي:** لا تقل عن **4GB RAM** (و8GB أفضل لو متاح)، لأن تحميل موديل لغوي يفهم العربية + موديل تحويل الصوت لنص + موديل نطق الصوت + نظام التشغيل سيحتاج حوالي **2.2GB إلى 2.8GB RAM** مفتوحة باستمرار.
  - ستحتاج إلى كارت ميموري سريع (**SanDisk Extreme A2** بحجم 32GB أو 64GB) لتحميل الموديلات عليه وتشغيلها بسرعة، مع **مروحة تبريد (Active Fan)**.

2. أنسب الموديلات لتحميلها على الـ Raspberry Pi (تشتغل Offline وتدعم العربي)

لكي يتكلم الجهاز ويسمع ويفكر والموديلات محملة عليه، ستقوم بتحميل **3 موديلات خفيفة ومضغوطة** تعمل معاً كمسار واحد (Pipeline) عبر أداة **Ollama** أو **llama.cpp**:

الوظيفة	أنسب موديل يتحمل على الـ Pi	الحجم على الـ Pi	لماذا هو الأنسب لمشروعك؟
1. الموديل اللغوي الذكي (LLM)	**Qwen 2.5 (1.5B-Instruct))** بصيغة GGUF Q4_K_M	**~1.0 GB**	أفضل موديل صغير يدعم **اللغة العربية** بطلاقة، ويدعم ميزة **Tool Calling** (ربط الإنترنت والداتابيز)، وسريع جداً على معالج الـ Raspberry Pi (حوالي 8–10 كلمات/ثانية على Pi 4، و20 كلمة/ثانية على Pi 5).
بديل LLM أقوى قليلاً	**Qwen 2.5 (3B-Instruct))** أو **Gemma 2 (2B)** بصيغة Q4_K_M	**~1.7 - 2.0 GB**	أذكى في صياغة ملخص حالة المريض لآخر يومين، لكنه أبطأ قليلاً على Pi 4 (حوالي 4–5 كلمات/ثانية)؛ ممتاز لو استخدمت Pi 5 أو شغلته على اللاب توب.
2. تحويل الصوت لنص (STT)	**Whisper.cpp (base أو small بصيغة Q5_0)**	**~150 - 250 MB**	يتحمل بالكامل على الـ Pi ويلقط كلام المريض أو أهله بالعربية ويحوله لنص محلياً (FR-NJ-001 و FR-HW-001).
3. نطق الكلام بالصوت (TTS)	**Piper TTS** (موديل عربي محمل على البوردة)	**~65 MB**	ينطق جمل "خد الدوا يا أستاذ حسين" أو "خلص التاسك يا أحمد" في **أقل من 0.2 ثانية** بدون استهلاك يُذكر من المعالج.

ملاحظة مفيدة للاب توب (2GB VRAM / 8GB RAM): موديل **Qwen 2.5 (1.5B)** حجمه **1GB فقط**؛ هذا يعني أنك تستطيع أيضاً تحميله على اللاب توب الخاص بك أثناء التطوير والاختبار، وسيعمل بالكامل داخل كارت الشاشة الـ **2GB VRAM** بسرعة فائقة جداً (أكثر من 45 كلمة/ثانية) دون أن يستهلك رامات اللاب توب!

3. كيف سيرتبط الموديل المحمل على الـ Pi بالإنترنت والتطبيق؟

بما أن الموديل محمل على الـ Raspberry Pi ولكن البوردة متصلة بالـ Wi-Fi والإنترنت (FR-HW-008)، فطريقة التشغيل البرمجية (بـ Python على الـ Pi) ستكون كالتالي لتجنب أي بطء:

1. **تنبيهات الأدوية والمهام ("خد الدوا يا أستاذ حسين" / "خلص التاسك يا أحمد"):**
   - التطبيق يرسل إشعاراً عبر الإنترنت (WebSockets أو Firebase أو MQTT) إلى الـ Raspberry Pi في موعد الدواء أو المهمة (FR-ALZ-006 و FR-ADHD-003 و FR-ADHD-010).
   - سكريبت الـ Python على الـ Pi يضيء الـ LED (FR-HW-006)، ويعرض التنبيه على الشاشة الـ 4 بوصة (FR-HW-007)، ويمرر الجملة لموديل الصوت المحمل على البوردة (**Piper TTS**) لينطق فوراً: "خد الدوا يا أستاذ حسين" أو "خلص التاسك يا أحمد".
   - عندما يرد المريض بصوته ("أخدته خلاص")، يحول **Whisper.cpp** الصوت لنص، ويفهم موديل **Qwen 2.5 (1.5B)** أن المريض أكد الجرعة، فيرسل تأكيداً للتطبيق لتسجيله في الداتابيز (FR-ALZ-007 و FR-ADHD-010).
2. **سؤال أهل المريض ("عمل إيه آخر يومين؟"):**
   - عندما يسمع الموديل سؤالاً عن حالة المريض أو نشاطه، يقوم كود الـ Python على الـ Pi بطلب بيانات آخر يومين من API التطبيق عبر الإنترنت (عدد المرات التي أخذ فيها الدواء، الأسئلة المتكررة، المهام المنجزة) (FR-ALZ-001 و FR-ALZ-009 و FR-ADHD-011).
   - كود الـ Python يضع هذه البيانات داخل Prompt قصير ويعطيها لموديل **Qwen 2.5 (1.5B)** المحمل على الـ Pi: "هذه بيانات المريض آخر يومين: *[البيانات]*. لخصها لأهل المريض في جملتين بالعامية"، ثم ينطق الموديل الملخص.
3. **البحث في الإنترنت ("درجة الحرارة كام؟" أو أسئلة عامة):**
   - عندما يسأل المستخدم عن الطقس أو معلومة حديثة (FR-NJ-005)، يقوم كود الـ Python على الـ Pi بجلب النتيجة من الإنترنت (عبر مكتبة duckduckgo-search أو OpenWeatherMap API)، ويعطي النتيجة النصية لموديل **Qwen 2.5 (1.5B)** المحمل على البوردة ليصيغها ويرد بها صوتياً (FR-NJ-001 و FR-NJ-005).